第 9 章：对话型 Agent 开发

版本: v2.5 (2026-03-23 全书完成) **作者**: 内容撰写专家（场景篇）
状态: review（待技术审核）
最后更新: 2026-03-23

本章涉及面试题

1. **如何保持多轮对话的上下文连贯性？**（涉及 9.2、9.4 节）
2. **如何设计 Agent 的人格设定？人格设定需要包含哪些要素？**（涉及 9.3 节）
3. **如何识别用户情绪异常？检测到不满时应该如何处理？**（涉及 9.6 节）
4. **对话型 Agent 的记忆如何分层管理？各层存储什么内容？**（涉及 9.2 节）
5. **如何处理对话中的指代消解（如「他」「这个」「刚才说的」）？**（涉及 9.4 节）

本章概述

学习目标： - 理解对话型 Agent 的核心挑战：上下文连贯性、个性化、情绪感知 - 掌握记忆管理策略和人格设定方法 - 能够设计多轮对话处理流程和情绪识别干预机制 - 理解对话型 Agent 的最佳实践与常见陷阱

核心知识点： - 对话型 Agent 场景分类与核心挑战 - 三层记忆管理策略（短期/长期/工作记忆） - 人格设定五要素与一致性维护 - 多轮对话处理（上下文窗口、指代消解、话题追踪） - 情绪识别方法与流程干预机制

9.1 需求分析

9.1.1 对话型 Agent 场景分类

对话型 Agent 根据应用场景可分为四类，每类有不同的设计重点：

| 场景类型 | 典型用例 | 设计重点 | 记忆策略 | |---------|---------|---------|---------| | **客服对话** | 解答问题、处理投诉、引导操作 | 准确性、规范性 | 短期记忆为主，记录用户问题历史 | | **个人助理** | 日程管理、提醒、信息查询 | 效率、主动性 | 长期记忆存储用户习惯和偏好 | | **陪伴聊天** | 情感交流、闲聊、兴趣讨论 | 共情、个性化 | 长期记忆存储兴趣和关系历史 | | **创意协作** | 头脑风暴、方案讨论、内容共创 | 开放性、引导性 | 工作记忆记录创意进展和设定 |

核心差异分析：- **客服场景**重准确性，回答必须与官方信息一致，不能自由发挥 - **助理场景**重效率，需要主动提醒和预测用户需求 - **陪伴场景**重共情，需要理解用户情绪并给予情感回应 - **创意场景**重开放性，需要引导用户发散思考而非给出标准答案

> **关键定义**：漫剧创意沟通 Agent 属于**创意协作场景**，需要开放性引导而非标准答案，记忆策略需要同时维护短期对话历史和长期用户偏好。

9.1.2 核心挑战：上下文连贯性

为什么上下文连贯性是对话型 Agent 的核心挑战?

LLM（大型语言模型）本身是**无状态**的，每次调用都是独立的计算过程，不记得之前的对话。这意味着：

```
问题根源：LLM 无状态特性
│
├── 窗口限制：上下文窗口有限（8K/128K token），长对话需要截断
│
├── 指代消解：用户说「他」「这个」「刚才说的」，需要解析指代对象
│
└── 话题追踪：对话可能多个话题交织，需要记录当前话题和切换历史
```

具体挑战分析：

1. **窗口限制**：主流模型上下文窗口从 8K 到 200K 不等，但成本随窗口增大而增加。实际应用中需要在成本和连贯性之间权衡。

2. **指代消解**：用户说「把刚才那个设定改一下」，Agent 需要知道「刚才那个」指哪个设定。这需要维护对话实体的提及历史。

3. **话题追踪**：对话可能在「角色设定」「剧情大纲」「世界观」之间切换，需要记录话题历史以支持「回到刚才的话题」这类请求。

> **注意**：认为「把全部历史塞进上下文就好」是常见误区。实际窗口有限且成本高，需要智能的记忆管理策略。

9.1.3 核心挑战：个性化

为什么需要个性化?

用户期望 Agent 记住自己的偏好、历史、习惯，而不是每次都重新介绍。

个性化维度：

维度	示例	实现方式
称呼偏好	「叫我老王」「别叫我先生」	长期记忆存储，对话时检索注入
回复风格	「喜欢简洁」「不要太啰嗦」	长期记忆存

储，调整生成参数 | | **兴趣标签** | 「玄幻迷」「不喜欢现代题材」 | 向量数据库存储，创意生成时检索 | | **交互习惯** | 「早上活跃」「晚上不回复」 | 时间序列记录，调整推送策略 |

实现方式： 1. 长期记忆存储用户画像（**向量数据库**：支持语义检索的数据库） 2. 对话时检索 **Top-K**（最相关的 K 条）相关偏好注入上下文 3. 新信息写入、旧信息衰减（时间衰减权重） 4. 核心设定变更需用户确认

> **隐私边界**：哪些信息应该存储、哪些不应该、用户如何查看/删除自己的数据，这是个性化设计必须考虑的问题。建议提供用户设置界面，让用户明确知道存储了什么、可以删除什么。

9.1.4 本节小结

对话型 Agent 分客服/助理/陪伴/创意四类，核心挑战是**上下文连贯性**（窗口限制、指代消解、话题追踪）和**个性化**（用户画像、隐私边界），需要智能记忆管理策略。

9.2 方案设计：记忆管理策略

总：对话型 Agent 的记忆分为三层——短期记忆存对话历史、长期记忆存用户画像、工作记忆存任务状态，三层协同工作保证对话连贯性和个性化体验。

9.2.1 短期记忆（对话上下文）

定义：短期记忆存储最近 N 轮对话（用户输入 + Agent 回复），保证对话的即时连贯性。

实现方式对比:

| 方式 | 说明 | 适用场景 | 优缺点 | |------|------|---------|-------| | **ConversationBufferMemory** | 存储全部对话历史 | 短对话（<20 轮） | 优点：完整；缺点：token 消耗大 | | **ConversationBufferWindowMemory** | 只保留最近 N 轮 | 长对话场景 | 优点：可控；缺点：丢失早期信息 | | **ConversationSummaryMemory** | 用 LLM 摘要早期对话 | 超长对话 | 优点：节省 token；缺点：摘要可能丢失细节 |

截断策略： 1. **固定窗口**：保留最近 10-20 轮对话 2. **Token 计数**：不超过 4K-8K token 3. **时间窗口**：保留最近 30 分钟的对话

优化技巧： - **摘要压缩**：当对话超过窗口时，用 LLM 摘要早期对话（「前 10 轮讨论了角色 A 和角色 B 的设定」） - **关键信息提取**：从早期对话提取事实性信息（设定、偏好）注入长期记忆，对话历史可丢弃

> **最佳实践**：漫剧创意沟通用**窗口记忆**保留最近 15 轮对话，超过后用 LLM 摘要早期内容保留关键设定，平衡连贯性和成本。

9.2.2 长期记忆（用户画像与历史）

定义：长期记忆存储用户偏好、历史交互、重要事实，支持语义检索和个性化注入。

实现架构：

```
┌──────────────────────────────────────────────────────┐
│ 长期记忆（向量数据库）
│ ├──────────────────────────────────────────────────────┤
│ 用户偏好：「不要现代题材」「喜欢多主角」│
│ 历史交互：第 1-5 章创意沟通记录 │
│ 重要事实：作者是网络小说作家、玄幻迷 │
│ 情绪历史：对「都市题材」有负面反馈 │
└──────────────────────────────────────────────────────┘
↑ ↑
对话时检索 Top-K 新信息写入
注入上下文 + 旧信息衰减
```

检索策略： - 对话时检索 Top-K 相关记忆（K=3-5）注入上下文 - 用**嵌入模型**（将文本转换为向量的模型）将用户表述向量化，检索语义相似的記憶 - 检索结果按相关性和时间衰减加权排序

更新机制： 1. **新信息写入**：用户明确表达的偏好直接写入 2. **旧信息衰减**：时间衰减权重（如 30 天前记忆权重降为 50%） 3. **用户确认**：核心设定变更需询问确认（「检测到您之前说喜欢玄幻，现在说不喜欢，是改变想法了吗？」）

> **常见误区**：长期记忆只存不更新。实际需要衰减和清理机制，避免过时信息干扰。例如用户 3 个月前说喜欢玄幻，但现在明确说不喜欢了，旧记忆应该衰减或被覆盖。

9.2.3 工作记忆（任务状态）

定义：工作记忆存储当前任务的中间状态、待办事项、进度追踪，支持任务中断恢复。

与短期记忆的区别：

维度	短期记忆	工作记忆
存储内容	对话历史（用户说了什么）	任务状态（做到哪一步了）
数据结构	文本列表（对话轮次）	结构化数据（JSON/Dict）
生命周期	对话结束可清除	任务完成才清除
用途	保证对话连贯性	支持任务中断恢复

实现方式： - 结构化存储（JSON/Dict），Agent 可读写更新 - 任务开始创建、任务完成清除、支持中断恢复

案例：漫剧生成任务工作记忆记录：`json { "task": "漫剧大纲生成", "phase": "大纲生成", "progress": "3/5 章", "pending": ["角色 A 设定待确认"], "created_at": "2026-03-22T10:00:00Z" }`

> **关键区别**：短期记忆是「对话历史」，工作记忆是「任务状态」。例如短期记忆记录「用户说喜欢玄幻」，工作记忆记录「正在生成大纲，已完成 3/5 章」。

9.2.4 记忆冲突处理

问题：当新信息与旧记忆矛盾时，如何处理？

冲突类型：
1. **直接矛盾**：旧记忆「我喜欢玄幻」vs 新说「我不喜欢玄幻了」
2. **部分矛盾**：旧记忆「喜欢玄幻和仙侠」vs 新说「不喜欢仙侠」
3. **隐含矛盾**：旧记忆「不要现代题材」vs 新创意是现代题材

解决策略：

策略	说明	适用场景
时间优先	新信息覆盖旧信息	用户明确表达改变想法
来源优先	用户明确陈述优先于推断	明确表述 vs Agent 推断
置信度优先	计算综合置信度（来源/时间/一致性）	复杂冲突场景
用户确认	核心设定冲突时询问用户	重要设定变更

实现流程：`检测冲突 → 计算置信度 → 判断是否需确认 → 更新记忆 → 记录变更历史 │ │ │ │ │ └─ 核心设定 → 询问用户 │ └─ 高置信度 → 直接更新 └─ 相似度<0.5 → 判定为冲突`

> **最佳实践**：漫剧系统检测到作者改变题材偏好时，询问确认「检测到您之前说喜欢玄幻，现在说不喜欢，是改变想法了吗？」，更新长期记忆并记录变更时间。

9.2.5 本节小结

记忆分三层：**短期记忆**存对话历史（窗口/摘要），**长期记忆**存用户画像（向量检索），**工作记忆**存任务状态（结构化）。冲突处理需要综合时间/来源/置信度判断，核心设定变更需用户确认。

9.3 方案设计：人格设定与一致性

总：人格设定包含角色定位、语言风格、知识边界、价值观、交互方式五要素，一致性需要持续注入和漂移检测，个性化适配在核心人格框架内调整。

9.3.1 人格设定五要素

完整的人格设定应包含以下五要素:

| 要素 | 说明 | 示例（漫剧创意 Agent） | |------|------|----------------------| | **角色定位** | 身份描述 | 「专业漫剧策划师」「资深编剧顾问」 | | **语言风格** | 正式/casual、简洁/详细、幽默/严肃 | 「语言简洁直接，不用网络流行语」 | | **知识边界** | 明确能做什么、不能做什么 | 「擅长创意策划，不擅长法律建议」 | | **价值观** | 原则性声明 | 「尊重原创」「注重逻辑一致性」 | | **交互方式** | 主动引导 vs 被动响应、提问频率 | 「主动提问澄清需求，每 3 轮确认一次进展」 |

> **常见误区**：人格设定过于笼统（如「友好助手」）。实际需要具体描述角色、风格、边界、价值观、交互方式五要素。

设计建议： 1. **角色定位**要具体，避免「助手」这类泛化描述 2. **语言风格**要有可操作的描述（如「回复不超过 200 字」） 3. **知识边界**要明确，避免用户产生错误预期 4. **价值观**要体现专业性（如「注重逻辑一致性」） 5. **交互方式**要量化（如「每 3 轮确认一次」）

9.3.2 人格一致性维护

为什么人格一致性重要?

人格跳跃会让用户困惑（如前一句专业后一句卖萌），降低信任感。

维护方法： 1. **系统提示词固定人格**：每次调用 LLM 都注入人格描述 2. **对话中持续注入**：长对话中定期重新注入人格描述（如每 10 轮） 3. **输出前检查一致性**：用嵌入模型计算当前回复与人格描述的余弦相似度

漂移检测机制:
`生成回复 → 计算与人格描述的相似度 → 低于阈值告警 → 重新生成 | └ 阈值建议：0.75（**余弦相似度**：向量夹角余弦值，范围 -1 到 1）`

修复机制： - 检测到人设漂移时重新注入系统提示词 - 或标记该回复，由人工审核 - 或自动重新生成直到符合人格

> **案例**：漫剧 Agent 检测到回复过于随意（相似度 0.6<阈值 0.75），重新生成保持专业风格。

9.3.3 个性化适配

问题：如何在保持人格一致性的同时适应用户偏好?

解决方案：在核心人格框架内调整非核心要素。

适配维度:

| 维度 | 可调整 | 不可调整 | |------|-------|---------| | **回复长度** | ✅ 可根据用户反馈调整 | - | | **提问频率** | ✅ 可根据用户偏好调整 | - | | **专业程度** | ⚠️ 可微调但不能突破边界 | - | | **核心人格** | - | ❌ 专业 Agent 不能变成卖萌 | | **价值观** | - | ❌ 不能违背原则 |

实现流程: 1. 记录用户对回复风格的反馈（如「太啰嗦」「不够详细」） 2. 根据反馈调整语言风格、回复长度、提问频率 3. 边界检查：确保调整不突破人格核心 4. 提供设置界面让用户明确选择偏好

> **最佳实践**: 漫剧作者反馈「太啰嗦」，Agent 调整后续回复长度从 300 字降至 100 字，但保持专业风格（核心人格不变）。

9.3.4 本节小结

人格设定包含**角色/风格/边界/价值观/交互方式**五要素，一致性需要持续注入和漂移检测（相似度阈值 0.75），个性化适配在核心人格框架内调整（回复长度/提问频率可调，核心人格不可变）。

9.4 方案设计：多轮对话处理

总: 多轮对话处理需要管理上下文窗口（截断 + 摘要 + 关键信息提取）、解析指代消解（规则/LLM/向量检索）、追踪话题切换（记录话题历史支持回溯）。

9.4.1 上下文窗口管理

窗口限制: 主流模型上下文窗口从 8K 到 200K 不等，但成本随窗口增大而增加。

截断策略对比:

| 策略 | 说明 | 优点 | 缺点 | |------|------|------|------| | **固定轮数** | 保留最近 N 轮（N=10-20） | 简单可控 | 可能丢失关键信息 | | **Token 计数** | 不超过 X token（X=4K-8K） | 精确控制成本 | 实现稍复杂 | | **时间窗口** | 保留最近 N 分钟 | 符合时间直觉 | 对话密集时可能丢失 |

优化策略: 1. **摘要压缩**: 用 LLM 摘要早期对话（「前 10 轮讨论了角色 A 和 B 的设定」） 2. **关键信息提取**: 从早期对话提取事实性信息（设定、偏好）注入长期记忆，对话历史可丢弃

> **最佳实践**: 漫剧长对话用 Token 计数限制 6K，超过后用 LLM 摘要早期内容保留设定信息，平衡连贯性和成本。

9.4.2 指代消解

问题：用户说「把他的能力改一下」，Agent 如何知道「他」指谁？

指代类型： 1. **人称代词**：他/她/它 2. **指示代词**：这个/那个/这些 3. **省略**：「生成大纲」「要哪种？」

消解方法对比：

| 方法 | 说明 | 准确率 | 成本 | |------|------|-------|------| | **规则匹配** | 最近提及的实体优先 | 70-80% | 低 | | **LLM 推理** | Prompt「这句话中的『他』指谁？」 | 85-90% | 中 | | **向量检索** | 将指代表述向量化，检索最相关实体 | 80-85% | 中 |

实现技巧： - 在上下文中显式标注实体（「角色 A（张三）」），减少歧义 - 不确定时主动确认（「您说的是角色 A 吗？」）

> **常见误区**：依赖 LLM 自动消解。实际 LLM 可能猜错，最好显式确认。例如作者说「把他的能力改一下」，Agent 检索最近讨论的角色是「角色 A」，回复确认「您说的是角色 A 吗？」

9.4.3 话题追踪与切换

问题：对话可能在多个话题之间切换，如何追踪？

话题识别： - 用关键词或嵌入模型识别当前话题（如「角色设定」「剧情大纲」「世界观」） - 记录话题切换历史（「角色设定→剧情大纲→角色设定」）

话题内连贯： - 同一话题内保持术语一致、设定一致 - 话题内实体提及历史用于指代消解

话题切换处理： 1. 检测切换时确认（「我们先放下角色设定，开始讨论剧情大纲对吗？」） 2. 记录切换点，支持「回到刚才的话题」请求 3. 切换时保存当前话题状态到工作记忆

> **最佳实践**：漫剧对话从「角色设定」切换到「剧情大纲」，Agent 确认切换并记录话题历史支持回溯。用户说「回到角色设定」时，Agent 能准确恢复到之前的话题状态。

9.4.4 本节小结

上下文窗口管理用**截断 + 摘要 + 关键信息提取**，指代消解用**规则/LLM/向量检索**（不确定时主动确认），话题追踪**记录切换历史**支持回溯。

9.5 最佳实践与陷阱

9.5.1 最佳实践

| 实践 | 说明 | 案例 | |------|------|------| | **记忆分层清晰** | 短期/长期/工作记忆职责明确，不混用 | 漫剧系统三层记忆独立存储 | | **人格设定具体** | 角色/风格/边界/价值观/交互方式五要素完整 | 漫剧 Agent 人格文档 500 字 | | **主动确认关键信息** | 指代消解、话题切换、设定变更时主动确认 | 「您说的是角色 A 吗？」 | | **情绪感知** | 连续 2 轮情绪分数<50 时，切换交互方式 | 检测不满时停止生成并询问 | | **用户控制** | 提供设置界面让用户管理记忆、调整偏好 | 用户可查看/删除存储的偏好 |

9.5.2 常见陷阱

| 陷阱 | 后果 | 解决方案 | |------|------|---------| | **记忆过载** | 存储太多细节导致检索噪声 | 只存关键信息，定期清理 | | **人格漂移** | 长对话后人设不一致 | 持续注入人格描述，定期检测（阈值 0.75） | | **指代错误** | 猜错指代对象导致答非所问 | 主动确认而非猜测 | | **情绪忽视** | 用户不满继续强行推进 | 情绪检测 + 流程干预（见 9.6 节） | | **隐私风险** | 存储敏感信息未加密 | 敏感信息加密存储，提供删除接口 |

> **案例**：漫剧 Agent 检测作者连续负面反馈后停止生成，询问「有什么需要改进的地方吗？」，避免加剧用户不满。

9.5.3 本节小结

最佳实践包括**记忆分层、人格具体、主动确认、情绪感知、用户控制**，常见陷阱是**记忆过载、人格漂移、指代错误、情绪忽视、隐私风险**。

9.6 情绪识别与流程干预

总：情绪识别需要综合文本分析、关键词和语气三种方法，阈值设定分级响应（正常>60/轻度负面 30-60/重度负面≤30），干预机制核心是 5 秒内停止生成并转向问题解决，情绪记忆管理 30 天内避免重复触发负面体验。

9.6.1 情绪识别方法

三种方法综合判断：

| 方法 | 说明 | 权重 | 示例 | |------|------|------|------| | **文本情绪分析** | 使用情绪分类模型（正面/负面/中性） | 50% | 调用百度 NLP API | | **关键词检测** | 建立负面情绪词库匹配 |

30% | 「不满意」「太差了」「投诉」 | | **语气分析** | 检测感叹号密度、反问句、重复表达 | 20% | 连续 3 个感叹号、同一问题问 3 次 |

综合评分公式：`情绪分数 = 情绪分析 × 50% + 关键词 × 30% + 语气 × 20%`

> **常见误区**：只依赖单一方法（如只用关键词）。实际需要综合判断，避免误报（如用户说「太好了」含「太」但不是负面）。

9.6.2 情绪阈值设定

分级响应机制：

| 级别 | 情绪分数 | 响应策略 | |------|---------|---------| | **正常** | > 60 | 继续当前流程，无需特殊处理 | | **轻度负面** | 30-60 | 主动询问「有什么需要改进的地方吗？」 | | **重度负面** | ≤ 30 | 立即触发干预流程，停止当前任务 |

动态调整：根据用户历史情绪记录调整阈值（如某用户容易激动，阈值适当提高）。

> **案例**：漫剧生成系统设定轻度负面阈值为 50 分，检测到作者对大纲不满意时主动询问「您希望调整剧情节奏还是角色设定？」

9.6.3 流程干预机制

重度负面情绪的干预流程：

`检测重度负面 → 停止生成 → 道歉与补救 → 转人工/降级 │ │ │ │ │ └─ 提供具体解决方案 │ └─ 保存进度，避免浪费 Token └─ 分数 ≤ 30 触发`

干预策略： 1. **中断当前任务**：立即停止生成，保存当前进度 2. **道歉与补救**：承认问题（「抱歉没有理解您的需求」），提供具体解决方案 3. **转人工客服**：严重负面情绪（分数 < 20）或连续 3 次轻度负面时，提供转接人工选项 4. **降级策略**：从自动生成切换到引导模式（让用户选择模板或提供示例）

> **最佳实践**：漫剧创意沟通检测到作者重度负面时，停止生成并回复「抱歉我的理解有偏差，您能否提供一个参考案例，或我为您转接人工策划师？」

9.6.4 情绪记忆管理

问题：如何避免重复触发用户负面情绪？

解决方案：记录用户情绪历史，生成内容前检索避开曾触发不满的方向。

实现方式： 1. **记录情绪历史**：将每次交互的情绪分数存入长期记忆（向量数据库），标注触发负面情绪的主题 2. **避免重复触发**：生成内容前检索情绪历史，避开用户曾表达不满的方向 3. **个性化调整**：根据用户偏好调整交互方式 4. **情绪衰减**：旧的情绪记录随时间衰减权重（如 30 天前的负面记录权重降为 50%）

> **案例**：漫剧系统记录作者对「都市题材」的负面反馈，下次创作时优先询问「这次想尝试玄幻还是仙侠题材？」避开曾触发不满的方向。

9.6.5 本节小结

情绪识别需要**综合文本分析、关键词和语气**三种方法，阈值设定**分级响应**（正常>60/轻度负面 30-60/重度负面≤30），干预机制核心是**5 秒内停止生成并转向问题解决**，情绪记忆管理**30 天内避免重复触发**负面体验。

9.7 简单举例

案例设计

- 案例名称：漫剧创意沟通 Agent
- 涉及知识点：对话型 Agent 的记忆管理、人格设定、多轮对话处理、情绪识别与流程干预
- 案例目标：帮助理解如何设计一个能够与作者流畅沟通漫剧创意的对话型 Agent
- 案例内容要点：
- 场景描述：作者与 Agent 沟通漫剧创意，多轮对话中讨论角色设定、剧情大纲、世界观
- 技术应用：短期记忆保留最近 15 轮对话并摘要早期内容，长期记忆存储作者偏好并检索注入，设定专业策划师人格，检测连续 3 次负面反馈时干预
- 效果说明：多轮对话连贯（指代消解准确率>90%）、人格一致（相似度>0.75）、情绪感知<10 秒响应，作者体验流畅
- 注意事项：不展开情绪识别的具体算法实现（见 9.6 节）

知识来源: - LangChain Memory 官方文档 - https://python.langchain.com/docs/modules/memory/ - AutoGen GroupChat 官方文档 - https://microsoft.github.io/autogen/docs/groupchat - ReAct 论文：Reasoning and Acting in Language Models (ICLR 2023) - https://arxiv.org/abs/2210.03629

修改记录: - v2.2 (2026-03-23): 量化指标 — 模糊表述改为具体数字（情绪阈值、响应时间、准确率） - v2.1 (2026-03-23): 术语定义 — 首次出现必定义（LLM、向量数据库、Top-K、嵌入模型、余弦相似度） - v2.0 (2026-03-23): 文字润色 — 句子简化、删除重

复、优化结构 - v1.1 (2026-03-22): 根据编辑统筹意见修改 — 规范知识来源格式（2-3 个权威来源） - v1.0 (2026-03-22): 初稿完成